

See discussions, stats, and author profiles for this publication at: <https://www.researchgate.net/publication/389319627>

Da Inteligência Artificial à Inteligência Geográfica, InforGeo, nº 27

Article · February 2025

CITATIONS

0

READS

18

1 author:



[Rui Ferreira](#)

University of Coimbra

60 PUBLICATIONS 123 CITATIONS

SEE PROFILE

Da Inteligência Artificial à Inteligência Geográfica



Rui FERREIRA

Departamento de Geografia e Turismo, Faculdades de Letras, Universidade de Coimbra;
rff@uc.pt

Resumo: A Inteligência Artificial (IA) tem recebido nos últimos anos uma enorme atenção, não apenas no contexto académico ou das empresas tecnológicas, mas também do público em geral que, de modo crescente, tem vindo a tomar contacto com a sua aplicação concreta e a sentir, direta ou indiretamente, os efeitos indeléveis da expansão destas tecnologias. A integração da IA na Geografia potencia o desenvolvimento de abordagens inovadoras para lidar com uma variedade de problemas no ambiente e na sociedade humana. Neste artigo temos oportunidade de concretizar uma breve reflexão sobre o processo de evolução da IA no contexto histórico e das implicações que a sua integração nos métodos específicos da investigação geográfica acarretará a curto prazo para a identidade científica dos geógrafos.

Palavras-chave: GeoInteligência Artificial (GeoIA); Machine Learning (ML); Deep Learning (DL).

Introdução

Por boas ou más razões, a Inteligência Artificial (IA) é hoje um tema incontornável, tanto nos domínios académicos (pedagógicos, científicos e técnicos), como na esfera sociopolítica de discussão pública quotidiana. Ainda que muito deste ruído mediático esteja relacionado com receios gerados por um contexto social extremado e confrontacional, amplificados e retroalimentados pela onnipresença nas redes sociais, a verdade é que muitas das admiráveis capacidades da IA propaladas na última meia dúzia de anos traduzem mais o ultrapassar de uma barreira técnica do que a concretização de grandes avanços científicos nesta área de investigação. De facto, como recentemente ficou demonstrado pela surpreendente efusão da plataforma DeepSeek, é cada vez mais fácil e barato (em termos relativos) dispor da capacidade de processamento e do volume de dados necessário para se desenvolver uma ferramenta com capacidades que lhe permitem competir com os grandes gigantes da data economy.

Ou seja, o sucesso de ferramentas como ChatGPT, OpenAI ou Gemini não está propriamente centrado nas características intrínsecas da sofisticação do modelo usado ou nos notórios avanços técnicos dos métodos que lhes são subjacentes, mas sim numa muito mais prosaica capacidade de recolher, armazenar e processar gigantescos volumes de dados. Em síntese, na digitalização massiva das ações que sustentam o funcionamento da nossa sociedade suportada numa rede global de computadores. Esta é uma constatação que faz cair por terra uma certa mística frequentemente associada à IA e que, para uns, causa espanto e admiração (ou, em casos extremos, adoração) e, para outros, é motivo de pavor irracional e fatalismo auto e heterodestrutivo.

Neste pequeno texto reflexivo, procuraremos contribuir para uma compreensão racional desta tecnologia, focando a atenção em 3 pontos específicos: a) o contexto de evolução histórica e o quadro epistemológico da IA; b) a relação entre IA e a ciência geográfica; c) algumas referências sobre os modos de assimilação desta tecnologia em diversos ramos da ciência geográfica.

Breve sistematização histórico-metodológica da Inteligência Artificial

Embora a noção especulativa ou ficcionada de uma inteligência artificial, manufaturada por humanos ou, como prefere Harari (2024), a criação de uma “inteligência alienígena”, possa ser identificada em tempos bastante mais remotos (Poole & Mackworth, 2023), o horizonte temporal da IA situa-se no pós-II Guerra Mundial (Buchanan, 2005). Aliás, Moor (2006) propõe um momento bastante específico como “o evento que iniciou a IA como disciplina de investigação”: o Dartmouth Summer Research Project, realizado no Dartmouth College, New Hampshire, em 1956 e onde foi cunhado o termo “Inteligência Artificial”.

Estes primeiros anos (finais da década de 1950/inícios da de 60) constituem uma época fervilhante de ideias sobre a compreensão dos processos de raciocínio, inteligência e formação de conhecimento, envolvendo múltiplos domínios científicos que começam a reconhecer as vantagens da cooperação interdisciplinar. Mas são também marcados por fortes constrangimentos tecnológicos, tanto ao nível do hardware, como das linguagens de programação.

É neste contexto contrastante que, em 1956, o psicólogo A. Newell, o cientista político H. A. Simon e o programador de sistemas J. C. Shaw apresentaram o programa LT (Logic Theorist) (McCorduck, 2004). O LT foi o primeiro software criado para mimetizar as destrezas dos humanos na resolução de problemas, tendo sido aplicado para provar teoremas no cálculo proposicional, expressos na obra *Principia Mathematica*, de Whitehead e Russell, demonstrando assim a possibilidade de automatizar processos de aprendizagem envolvendo inteligência não humana e uma certa criatividade, indispensável para se alcançar as soluções dos teoremas.

Se nas décadas de 1950/1960 o foco de investigação estava centrado nos processos de raciocínio e no desenvolvimento de metodologias heurísticas para suportar a aprendizagem, ao longo da década de 1960 e inícios dos anos de 1970, ocorreu uma mudança de paradigma, ganhando importância a ideia de que o conhecimento é também fundamental para o comportamento inteligente. Em 1967, surgem os primeiros programas baseados em conhecimento aplicados em diversas áreas específicas (Ex.: DENDRAL, no raciocínio científico; MACSYMA, no raciocínio matemático; MacHack, nos desafios de xadrez) (McCorduck, 2004).

É também por esta altura que surge o programa LOGO, orientado para a criação de um ambiente dinâmico e interativo de aprendizagem e que ainda hoje é possível experienciar através do NetLOGO, uma evolução direcionada para múltiplas audiências, mas, em particular, para ajudar a desenvolver as capacidades de raciocínio algorítmico em crianças (Wilensky & Rand, 2015).

Durante as décadas de 1970 e 1980, vão surgindo novos avanços na compreensão dos métodos comuns de raciocínio que não são estritamente dedutivos, como o raciocínio baseado em casos, a analogia, a indução, o raciocínio sob incerteza e raciocínio por defeito. Ganham importância os métodos automatizados que permitem incorporar lógicas difusas, constrangimentos de dados ou que de alguma forma permitem lidar com a imperfeição ou as limitações dos processos de raciocínio.

Talvez não por acaso, em 1978, o prémio Nobel de Economia foi atribuído a Herbert A. Simon, pelo seu trabalho pioneiro sobre os processos de tomada de decisão dentro das organizações económicas. A sua investigação desafiou a noção clássica de "homem económico racional", propondo o conceito de racionalidade limitada, que preconizava que os indivíduos e as organizações tomam decisões com base em informações limitadas e capacidade cognitiva restrita. Assim, o mais

comum é chegarem a soluções "suficientemente boas" e não, necessariamente, ideais ou ótimas. Estas ideias, que ficaram associadas ao conceito de "satisficing" tiveram um impacto profundo em múltiplas áreas da sociedade, incluindo no desenvolvimento da inteligência artificial.

O final da década de 1980 é marcado pelos primeiros desenvolvimentos da World Wide Web e também pela tomada de consciência de que o comportamento inteligente pode ser exponenciado se for colocado numa perspetiva colaborativa. O desenvolvimento das redes de computadores à escala global, durante os anos de 1990, irá criar a infraestrutura necessária para se avançar nessa direção. A entrada no novo milénio marca uma nova etapa neste percurso, com os primeiros esforços para a criação de uma web semântica, capaz de incorporar lógica, inferência, representação de conhecimento e ação. Se quisermos traçar o Estado da Arte da Inteligência Artificial, estes continuam a ser os domínios mais salientes, não apenas em termos de inovação associada, mas também em termos de impacto direto nas nossas vidas quotidianas.

Tendo por base este esboço histórico, salientando os principais marcos evolutivos da IA, podemos agora tentar esboçar uma definição mais concreta sobre o que é e como é utilizada a IA. Como referem Choi et al., 2020, numa definição simplificada, podemos conceptualizar a Inteligência Artificial como um campo de investigação científica focado na automatização de tarefas intelectuais normalmente realizadas por humanos. Este é, portanto, um conceito abrangente, com uma infinidade de áreas de aplicação e que envolve múltiplos processos funcionando de forma sistémica. Frequentemente, para o leigo ou iniciante, o conceito de Artificial Intelligence é facilmente confundido com outros conceitos associados, como por ex.: Machine Learning (ML) ou Deep Learning (DL).

De facto, todos estes conceitos podem ser enquadrados num termo ainda mais genérico que corresponde à Ciência dos Dados, que é um domínio científico híbrido ou transdisciplinar, e que integra métodos estatísticos, ciência computacional, visualização e técnicas de engenharia e de validação de dados para realizar tarefas de simplificação e limpeza, processamento, análise, visualização e interpretação, geralmente, em grandes volumes de dados.

O objetivo principal da Ciência dos Dados é identificar padrões e pontos de interesse nos dados que permitam tomar decisões ou realizar previsões probabilísticas. A IA corresponde aos sistemas-máquina complexos que procuram replicar o processo de raciocínio humano escalado várias ordens de magnitude. Esta replicação pode assentar em processos de Aprendizagem Automática (Machine Learning) ou de Aprendizagem Profunda (Deep Learning).

Os processos de ML, tal como a própria designação sugere, envolvem procedimentos automatizados de aprendizagem através da experiência sem que seja necessária grande intervenção ou assistência de um ser humano.

Estes processos permitem que os computadores possam operar autonomamente, melhorando o seu desempenho e rigor de decisão através da experiência adquirida pelo processamento de novos dados.

Em termos operativos, os processos de ML podem ser segmentados em diversas fases:

1. Entrada de Dados:

Todo o processo inicia com a recolha e incorporação dos dados, que podem ser estruturados (Ex.: tabelas com colunas regularmente definidas) ou não estruturados (imagens, áudio, texto, etc.). Para que o agente analítico seja mais eficaz, tanto quanto possível, os dados devem ser expurgados de erros e inconsistências.

2. Divisão de Dados

Nesta fase, o agente analítico separa os dados em três partes: o conjunto de treino (usado para treinar o modelo); o conjunto de validação (usado para afinar os parâmetros de ponderação e avaliar o desempenho durante a fase de treino); o conjunto de teste (usado para avaliar o desempenho final do modelo quando aplicado a novos dados).

3. Escolha do Modelo

Existem múltiplos tipos de algoritmos que podem ser utilizados no contexto de Machine Learning, mas podemos sistematizá-los em 3 categorias principais: A) Modelos de Aprendizagem Supervisionada (Supervised Learning), em que a aprendizagem é feita com base nos rótulos associados aos dados. São exemplos deste tipo os modelos a Regressão Linear, as Árvores de Decisão ou as Redes Neurais. B) Modelos de Aprendizagem Não Supervisionada (Unsupervised Learning), em que a aprendizagem é feita sobre dados não rotulados. São exemplos deste tipo os modelos de Agrupamento (Clustering) ou da Redução de Dimensionalidade (Dimensionality Reduction) (Ex.: Análise de Componentes Principais). C) Modelos de Aprendizagem por Reforço (Reinforcement Learning), em que a aprendizagem é feita através de tentativa e erro, com recompensas ou penalizações com base nas ações implementadas (Ex.: Treinar um robô para caminhar).

4. Treino do Modelo

O algoritmo é “treinado” através do ajustamento dos seus parâmetros internos de controlo, visando minimizar os erros em relação aos resultados esperados. Geralmente, este é um processo iterativo, utilizando uma função de perda para avaliar a diferença entre os resultados previstos e os reais.

5. Avaliação e Ajuste

Durante a fase de treino, o modelo é avaliado com os dados que formam o conjunto de validação, para garantir que não esteja a memorizar as características expressas nos dados do conjunto de treino (sobreajustamento). É este mecanismo que permite ajustar os parâmetros de controlo do modelo (ex.: a taxa de aprendizagem) para melhorar o seu desempenho quando exposto a novos dados.

6. Teste e Implantação

Depois de treinado e ajustado, o modelo é testado no conjunto de teste por forma a verificar o seu grau de desempenho em dados novos. Se o desempenho for aceitável, o modelo tem condições para ser implementado, passando a produzir resultados com base em novos conjuntos de dados estáticos ou, preferencialmente, recolhidos em tempo real.

7. Aprendizagem Contínua

Alguns modelos de ML podem ser continuamente ajustados à medida que recebem novos dados, melhorando assim seu desempenho com a utilização.

Os processos de Deep Learning (DL) correspondem a uma subárea dos métodos de Machine Learning (ML), concretamente, aqueles que se baseiam na utilização de Redes Neurais Artificiais (RNA). Em termos simplistas, uma RNA funciona imitando o comportamento dos neurónios no cérebro humano, com base numa estrutura que integra, no mínimo, três "camadas" de neurónios artificiais conectados entre si. A camada de entrada destina-se à receção dos dados, enquanto a camada de saída é responsável pela produção dos resultados do modelo. Entre estas pode existir uma ou várias camadas ocultas que transformam os dados através de operações matemáticas e ativam neurónios com base nos pesos e funções de ativação. Na fase de treino do modelo, são calculados pesos e desvios (bias) para cada neurónio como base em funções de perda, retropropagação ou descida de gradiente que possibilitam um processo iterativo de ajustamento dos parâmetros e, conseqüentemente, um ajuste dinâmico da rede, o que melhora significativamente os resultados produzidos.

Através de agentes analíticos de Deep Learning é possível extrair padrões complexos a partir de grandes volumes de dados, tornando este método numa ferramenta poderosa e eficiente, especialmente, em tarefas de reconhecimento de voz ou de padrões visuais (visão computacional) ou ainda na tradução automática. Mas as áreas potenciais de aplicação destes modelos são, necessariamente, muito mais amplas e ganham um nível adicional de importância quando se associam ao estudo de fenómenos que possuem uma dimensão espacial ou espaço-temporal, como é o caso da generalidade dos objetos de estudos da ciência geográfica.

Inteligência Artificial e Geografia

A combinação de Inteligência Artificial (IA) com a Geografia deu origem a um nicho de investigação, geralmente, reconhecido como Geographic Artificial Intelligence (GeoAI), que aqui traduziremos para GeoInteligência Artificial (GeoIA). Esta integração tem permitido novas abordagens na análise de problemas espaciais, combinando processos de Machine Learning (ML), Deep Learning (DL) e Sistemas de Informação Geográfica (SIG).

Ainda que a utilização do termo GeoInteligência Artificial seja relativamente recente (cfr. Hu et al, 2019), a verdade é que o reconhecimento da importância dos métodos analíticos de Machine Learning associados à informação digital espacializada e integrada em Sistemas de Informação Geográfica tem uma pegada histórica bastante mais profunda remontando, pelo menos, à última década do século passado (por ex.: Hewitson & Crane, 1994; Lee; Cho & Wong, 1998; Dimuccio; Ferreira; Cunha, 2006; Dimuccio et al., 2008). Paralelamente, se o leque de aplicações iniciais estava predominantemente focado nas características e fenómenos físicos dos territórios, atualmente, existe uma maior diversidade de temáticas abordadas, que passam pelos domínios da geografia da saúde, da análise de padrões socioeconómicos, análise das redes sociais, geo-textos/semântica geoespacial e social sensing, etc. (cfr. Hu et al., 2019; Liu & Biljecki, 2022; Song & Yingjie, 2024).

Pese embora esta maior diversidade, há duas áreas que, tendo em conta o volume de referências bibliográficas disponível, continuam a evidenciar uma exploração mais intensiva destes recursos metodológicos nas análises realizadas: o processamento de imagens geoespaciais e a modelação e análise dos sistemas de transportes (Arundel et al. 2024; Cheng et al., 2024). No primeiro caso, a explicação dessa tendência deverá estar relacionada com o enorme volume de dados facilmente acessíveis, provenientes de uma plethora de plataformas e sensores para obtenção de imagens remotas, a par com a morosidade dos processos tradicionais de fotointerpretação. No segundo, os fatores causais não parecem ser tão evidentes, mas uma das causas poderá ser a intrínseca complexidade do funcionamento dos sistemas em questão, nomeadamente, no que diz respeito à sua dinâmica espaçotemporal, o que obriga à aplicação de metodologias sofisticadas com capacidade para dar respostas eficazes em tempo útil (Cheng et al, 2024).

Podemos encarar a GeoIA como uma área de saber dedicada ao desenvolvimento de modelos informáticos inteligentes que mimetizam os processos associados à perceção geográfica do território, o que envolve um raciocínio espacial intrínseco e uma abordagem de interação escalar na identificação dos fenómenos e dinâmicas que aí ocorrem. Através destes sistemas poderemos fazer avançar o conhecimento geográfico e ter uma visão mais atualizada e abrangente sobre as dinâmicas e interações dos sistemas físicos e humanos.

Contudo, para se ser competente nestes domínios de investigação não basta um bom conhecimento empírico da realidade local, regional ou nacional, é necessário um leque mais amplo de destrezas que passam pela compreensão de aspetos teóricas da IA e pelas capacidades práticas no âmbito computacional e de programação informática. Esta linha de formação continua a estar arredada das aspirações de boa parte, senão da maioria, dos jovens estudantes nos cursos de Geografia das universidades nacionais, o que levanta um sério entrave à expansão e à exploração de todo o potencial competitivo da ciência geográfica no domínio da GeoIA, acabando este vazio por ser preenchido por especialistas noutras áreas, especialmente, as que se relacionam com as tecnologias de informação digital.

A GeoInteligência Artificial está aqui! E agora?

A chegada da GeoInteligência Artificial (GeoIA) marca uma nova era na investigação em Geografia e impõe profundas transformações no modo como lidamos com os problemas espaciais. A GeoIA não é apenas mais uma ferramenta tecnológica, é uma nova forma de pensar sobre o território e de tomar decisões com impactos diretos na sua gestão e sustentabilidade.

A massificação da Internet of Things (IoT) irá dar origem a um crescimento, ainda mais acelerado, do volume disponível de dados georreferenciados; a expansão das tecnologias de Realidade Aumentada e Virtual irá proporcionar (literalmente) novas formas de ver a realidade; a automação de Decisões Espaciais com recurso a GeoIA irá transformar profundamente o modo como tomamos decisões baseadas na localização, como gerimos as infraestruturas ou planeamos para situações de risco natural ou tecnológico. Todos estes cenários permitem imaginar o potencial que os modelos de Machine Learning e Deep Learning poderão vir a ter brevemente no contexto da Geografia.

A adaptação a estas novas realidades, que se aproxima a passos largos, gera já e, certamente, irá gerar no futuro próximo, muitos receios, dúvidas e críticas que não devem ser ignoradas ou menosprezadas. Todos os períodos de intensas mudanças criam tensões e disrupções nos tecidos sociais, políticos, económicos, institucionais, geracionais, relacionais e mentais, com impactos individualizados e coletivos.

Estas tecnologias disruptivas colocam muito poder nas mãos dos indivíduos que as criam e/ou dos governos que as controlam, poder que pode ser mal usado. Por isso, concordamos com Ray Solomonoff, um dos organizadores do Dartmouth Summer Research Project, quando afirma (cit. em Moor, 2006) que o principal perigo do desenvolvimento da IA é político. Há um aspeto na aplicação destes instrumentos tecnológicos, tanto em meio académico, empresarial ou outro, que vai muito para além da dimensão técnica dos processos analíticos. Cada vez mais, é necessário estar consciente para as questões éticas e os impactos políticos, sociais e humanos do (mau) uso destas ferramentas.

Referências

- Buchanan, Bruce G. (2005). "A (Very) Brief History of Artificial Intelligence", *AI Magazine* 26(4): 53-60.
- Cheng, Tao; Haworth, James; and Ozkan, Mustafa Can (2024). "Spatiotemporal AI for Transportation" In Song, Gao & Yingjie, Hu (Ed.). *Handbook of geospatial artificial intelligence*. Boca Raton: CRC Press.
- Choi, Rene Y.; Coyner, Aaron S.; Kalpathy-Cramer, Jayashree; Chiang, Michael F.; and Campbell, J. Peter (2020). Introduction to Machine Learning Neural Networks and Deep Learning. *Translational Vision Science & Technology*, 9 (2), 14. <https://doi.org/10.1167/tvst.9.2.14>
- Dimuccio, LA; Ferreira, R, Cunha, L e Campar de Almeida, A (2008). Susceptibilidade aos incêndios florestais na Região Centro de Portugal. Utilização de ferramentas SIG e de um Modelo de Redes Neurais para ponderar os factores condicionantes. *Cadernos de Geografia*, (26/27), 179-188.
- Dimuccio, Luca António; Ferreira, Rui; Cunha, Lúcio (2006). "Aplicação de um modelo de redes neurais na elaboração de mapas de susceptibilidade a movimentos de vertente. Um exemplo numa área a sul de Coimbra (Portugal Central)" In *Actas do II Congresso Nacional de Geomorfologia - Geomorfologia, ciência e sociedade*, Vol. III, APGeom, Coimbra, pp. 281-289.
- Hewitson, Bruce C; Crane, Robert G (1994). *Neural Nets: Applications in Geography*. Dordrecht: Kluwer Academic Publishers.
- Lee, S; Cho, S & Wong, P M (1998). Rainfall Prediction using Artificial Neural Networks. *Journal of Geographic Information and Decision Analysis*, 2(2). <https://doi.org/10.1016/j.procs.2015.07.528>
- Liu, Pengyuan; Biljecki, Filip (2022). A review of spatially explicit GeoAI applications in Urban Geography. *International Journal of Applied Earth Observations and Geoinformation*, 112, 102936. <https://doi.org/10.1016/j.jag.2022.102936>
- McCorduck, Pamela (2004). *Machines Who Think. A Personal Inquiry into the History and Prospects of Artificial Intelligence*. Natick, Massachusetts: A K Peters, Ltd.
- Moor, James (2006). The Dartmouth College Artificial Intelligence Conference: The Next Fifty Years. *AI Magazine*, 27 (4), 87-91.
- Poole, David L. & Mackworth, Alan K. (2023). *Artificial Intelligence: Foundations of Computational Agents*, (3^a ed.). Cambridge: Cambridge University Press.
- Samantha T. Arundel; Kevin G. McKeehan; Wenwen Li, and Zhining Gu (2024). "GeoAI forSpatialImageProcessing" In Song, Gao & Yingjie, Hu (Ed.). *Handbook of geospatial artificial intelligence*. Boca Raton: CRC Press.
- Song, Gao; Yingjie, Hu (2024). *Handbook of geospatial artificial intelligence*. Boca Raton: CRC Press.
- Wilensky, Uri & Rand, William (2015). *An Introduction to Agent-Based Modeling. Modeling Natural, Social, and Engineered Complex Systems with NetLogo*. Cambridge, Massachusetts: The MIT Press.
- Yingjie Hu, Song Gao, Dalton Lunga, Wenwen Li, Shawn Newsam, Budhendra Bhaduri (2019). GeoAI at ACM SIGSPATIAL: progress, challenges, and future directions. *SIGSPATIAL Special*, 11 (2), 5-15. <https://doi.org/10.1145/3377000.3377002>
- Yuval Noah Harari (2024). *Nexus. A Brief History of Information Networks From The Stone Age to AI*. New York: Random House.

INFOERGEO